UNIVERSIDAD DE GUANAJUATO

Inteligencia de Negocios

Agosto-Diciembre 2020

Martes – Jueves

10:30 – 13:00

UNIVERSIDAD DE GUANAJUATO

- R maneja directorios de trabajo. Básicamente, es donde se almacenan los archivos relacionados al proyecto
  - **getwd()** – obtiene el directorio actual de trabajo
  - **setwd()** – establece una ruta para el directorio de trabajo

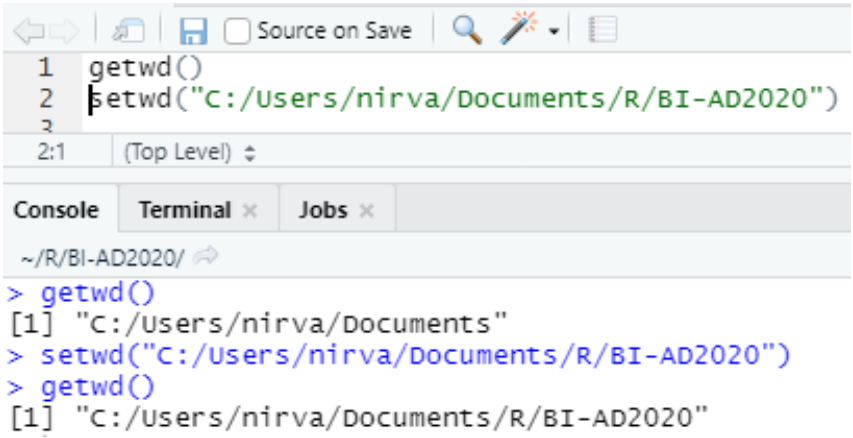

Más info

- **list.files()** – muestra todos los archivos en el directorio de trabajo.
- **list.dirs()** – muestra todas las carpetas en el directorio de trabajo.

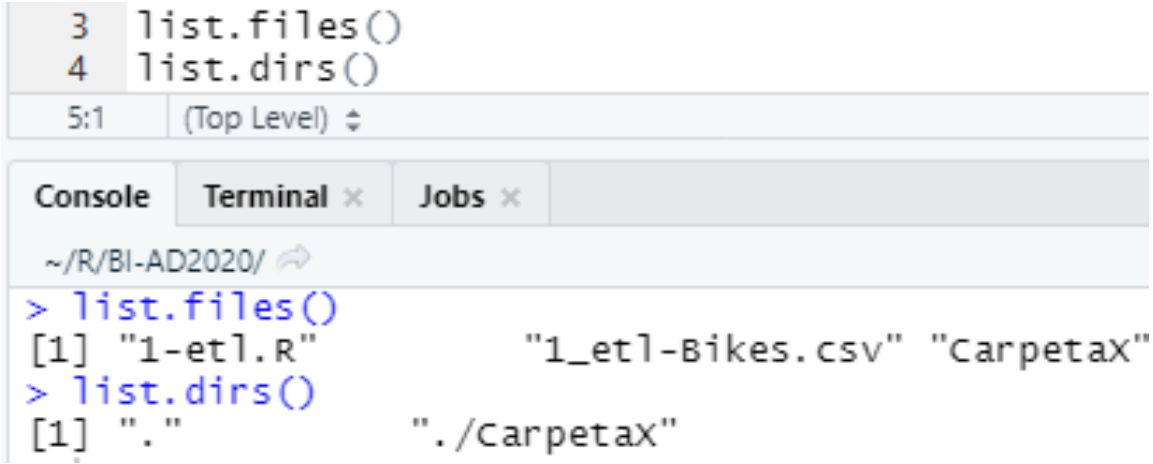

EXTRACCIÓN, TRANSFORMACIÓN Y CARGA

- ETL es un proceso enfocado a obtener, manipular y almacenar datos para cumplir con las necesidades de negocio o análisis. Puede considerarse como el punto de inicio de un proyecto de Inteligencia de Negocios.

- Es una compañía, iniciada en 2011, que opera una flota de bicicletas de alquiler público en un área metropolitana. Sus clientes son oficinistas de gobierno y empresas, y estudiantes del área urbana. Los clientes pueden fácilmente rentar bicicletas dentro de una red de estaciones en toda la ciudad; siendo así, que pueden rentar una bicicleta en una estación y dejarla en otra.

- Bicicleta compartida ha tenido un crecimiento continuo. Debido a esto, se estableció un grupo de Inteligencia de Negocios para realizar seguimiento de los datos almacenados acerca de sus transacciones, clientes y factores relacionados con las rentas. En 2014, comenzaron a entender como podrían usar los datos almacenados para guiar decisiones relacionadas a ventas, operaciones y publicidad.
- Como parte del grupo de Inteligencia de Negocios, se le ha proporcionado los datos de las rentas del periodo del 01/01/2011 – 31/12/2012.

Bicicleta compartida: Diccionario de datos

UNIVERSIDAD DE GUANAJUATO

- `datetime`: Hourly date + timestamp
- `season`: `1` = spring, `2` = summer, `3` = fall, `4` = winter
- `holiday`: Whether the day is considered a holiday
- `workingday`: Whether the day is neither a weekend nor holiday
- `weather`:
    - `1`: Clear, Few clouds, Partly cloudy, Partly cloudy
    - `2`: Mist + Cloudy, Mist + Broken clouds, Mist + Few clouds, Mist
    - `3`: Light Snow, Light Rain + Thunderstorm + Scattered clouds, Light Rain + Scattered clouds
    - `4`: Heavy Rain + Ice Pellets + Thunderstorm + Mist, Snow + Fog
- `temp`: Temperature in Celsius
- `atemp`: *Feels like* temperature in Celsius
- `humidity`: Relative humidity
- `windspeed`: Wind speed
- `casual`: Number of non-registered user rentals initiated
- `registered`: Number of registered user rentals initiated
- `count`: Number of total rentals

Bicicleta compartida: Vista del archivo

UNIVERSIDAD DE GUANAJUATO

	A	B	C	D	E	F	G	H	I	J	K	L
1	datetime	season	holiday	workingday	weather	temp	atemp	humidity	windspeed	casual	registered	count
2	01/01/2011 00:00	1	0	0	1	9.84	14.395	81	0	3	13	16
3	01/01/2011 01:00	1	0	0	1	9.02	13.635	80	0	8	32	40
4	01/01/2011 02:00	1	0	0	1	9.02	13.635	80	0	5	27	32
5	01/01/2011 03:00	1	0	0	1	9.84	14.395	75	0	3	10	13
6	01/01/2011 04:00	1	0	0	1	9.84	14.395	75	0	0	1	1
7	01/01/2011 05:00	1	0	0	2	9.84	12.88	75	6.0032	0	1	1
8	01/01/2011 06:00	1	0	0	1	9.02	13.635	80	0	2	0	2
9	01/01/2011 07:00	1	0	0	1	8.2	12.88	86	0	1	2	3
10	01/01/2011 08:00	1	0	0	1	9.84	14.395	75	0	1	7	8
11	01/01/2011 09:00	1	0	0	1	13.12	17.425	76	0	8	6	14
12	01/01/2011 10:00	1	0	0	1	15.58	19.695	76	16.9979	12	24	36
13	01/01/2011 11:00	1	0	0	1	14.76	16.665	81	19.0012	26	30	56
14	01/01/2011 12:00	1	0	0	1	17.22	21.21	77	19.0012	29	55	84
15	01/01/2011 13:00	1	0	0	2	18.86	22.725	72	19.9995	47	47	94
16	01/01/2011 14:00	1	0	0	2	18.86	22.725	72	19.0012	35	71	106
17	01/01/2011 15:00	1	0	0	2	18.04	21.97	77	19.9995	40	70	110
18	01/01/2011 16:00	1	0	0	2	17.22	21.21	82	19.9995	41	52	93
19	01/01/2011 17:00	1	0	0	2	18.04	21.97	82	19.0012	15	52	67
20	01/01/2011 18:00	1	0	0	3	17.22	21.21	88	16.9979	9	26	35

Extraer datos de los recursos: Importando datos de archivos CSV

UNIVERSIDAD DE GUANAJUATO

- datos <- **read.csv(*"{nombre_archivo}.csv"*)**
- datos <-**read.table(*"{nombre_archivo}.txt"* , sep="," header=TRUE)**

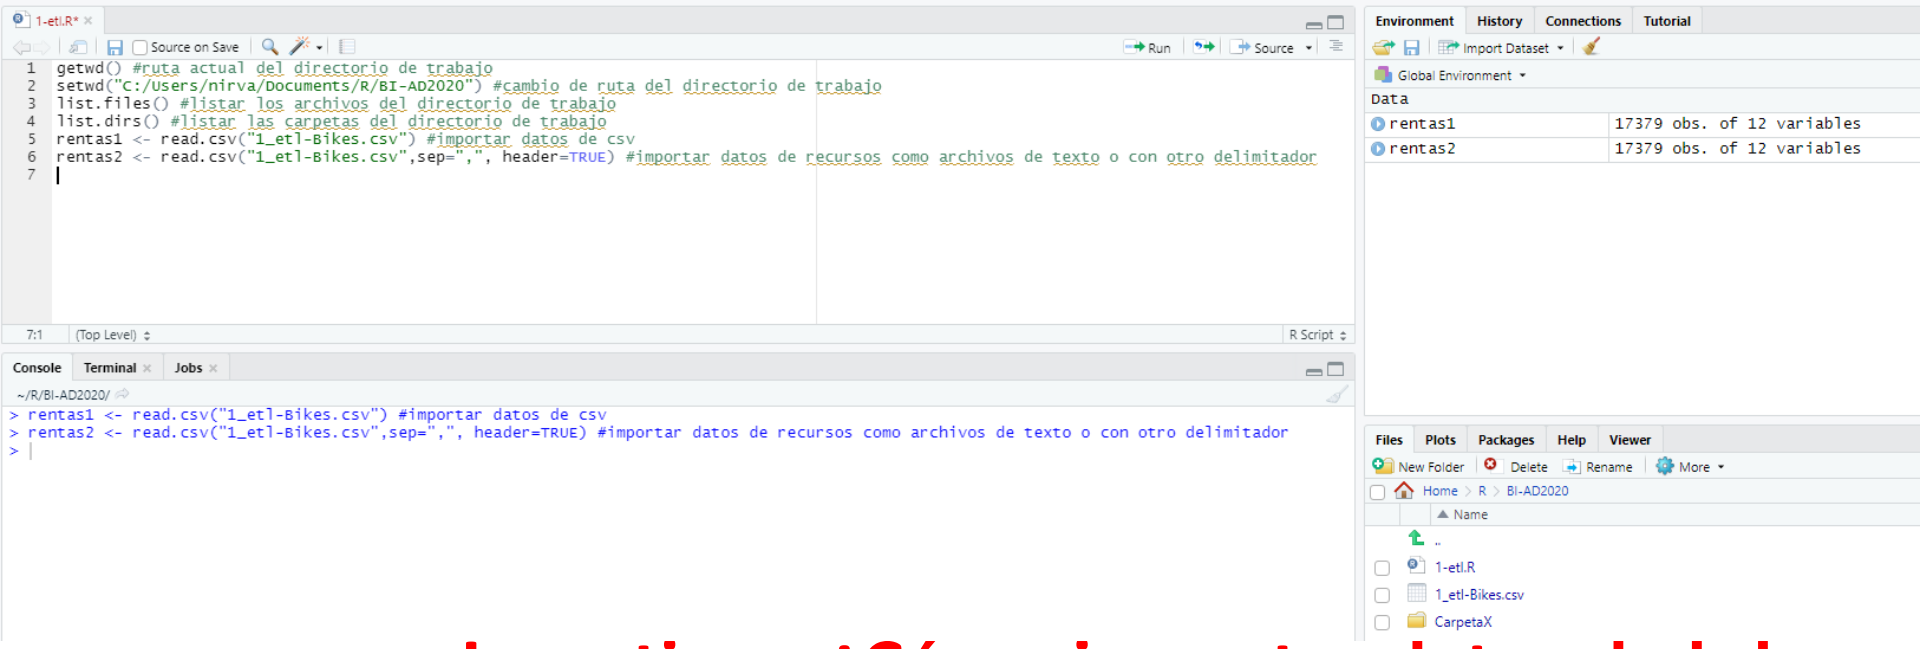

Investigar: ¿Cómo importar datos de bds relacionales en R?

Extraer datos de los recursos: Visualizando datos importados

UNIVERSIDAD DE GUANAJUATO

- **str(*objeto*)**

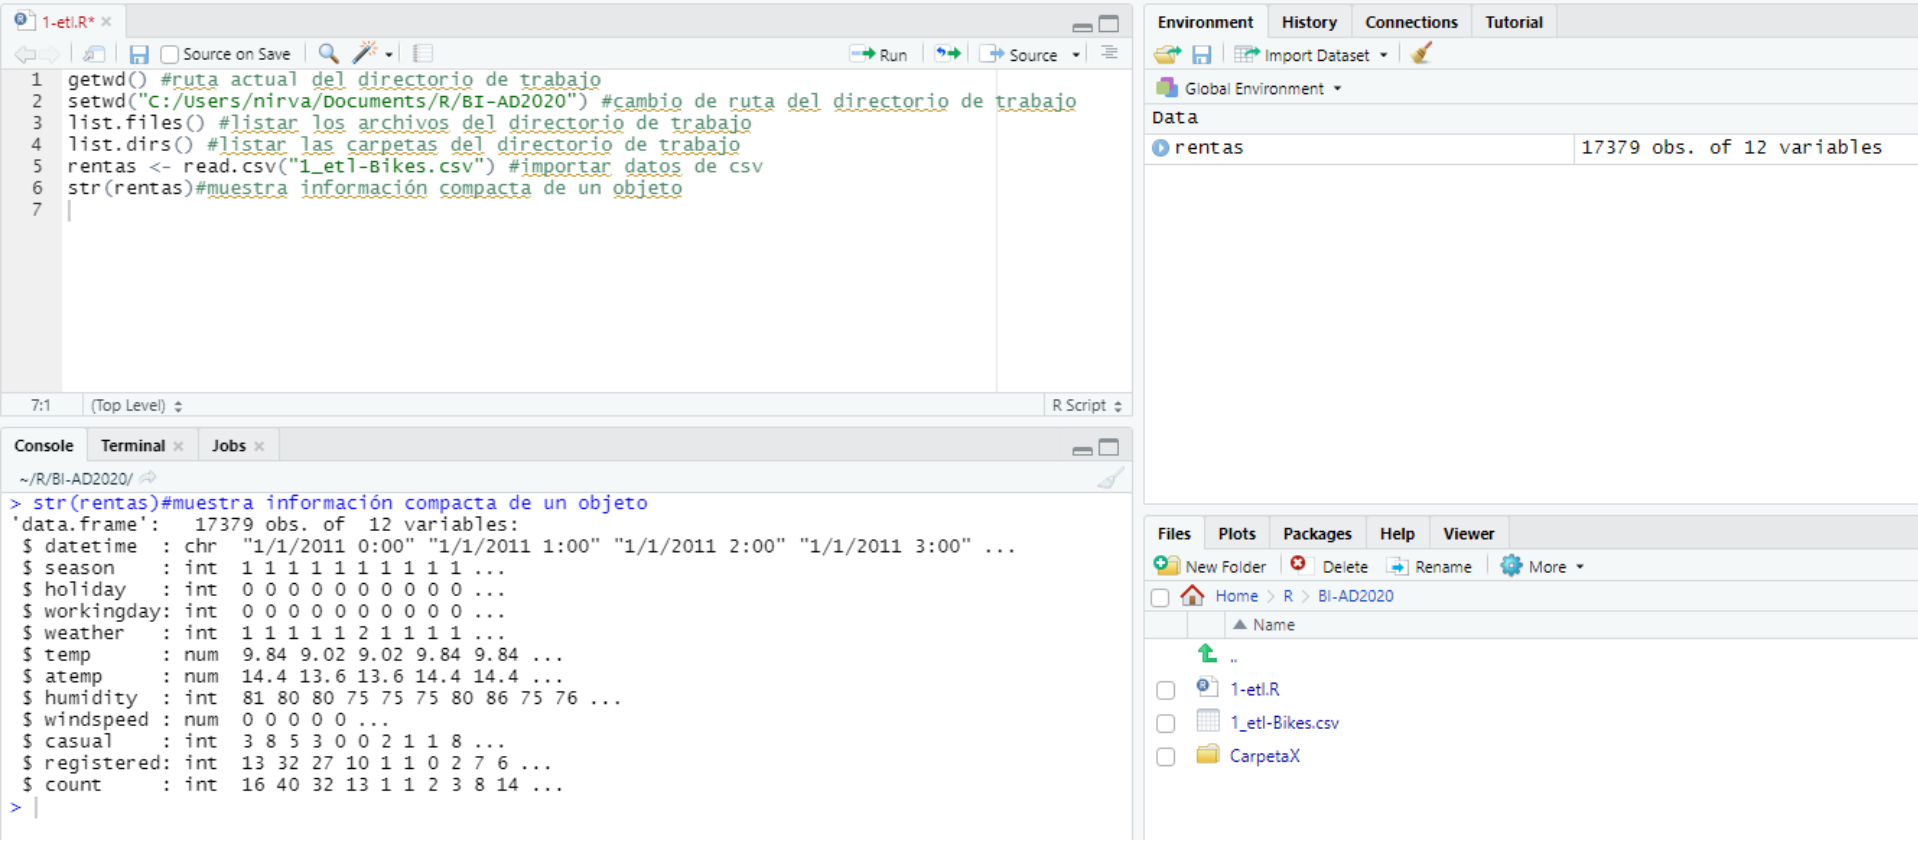

UNIVERSIDAD DE GUANAJUATO

- Instalar paquete *dplyr* para la manipulación de datos
  - **install.package(***"nombre_paquete"***)**

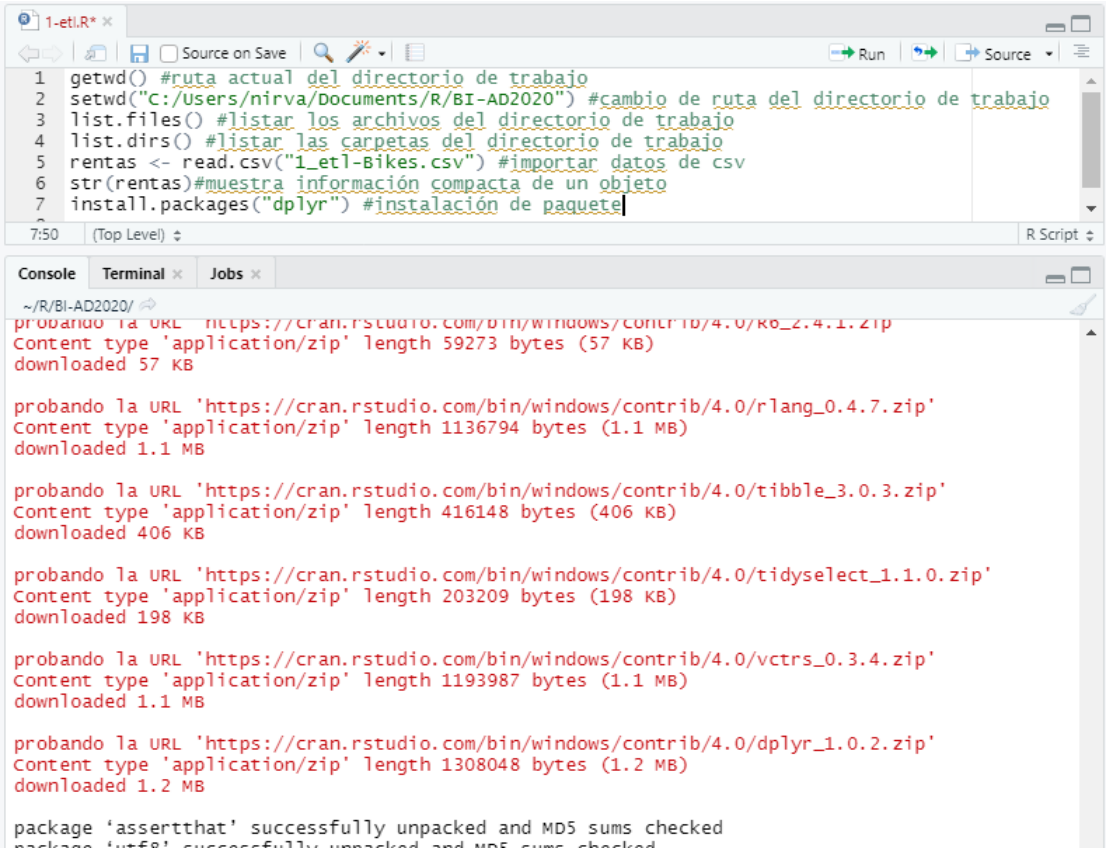

UNIVERSIDAD DE GUANAJUATO

- Cargar paquete
  - **library(*"nombre_paquete"*)**

```
8  library(dplyr) #cargar paquete para su uso
9
```

9:1 (Top Level) R Script

Console Terminal Jobs

~/R/BI-AD2020/

```
> library(dplyr) #cargar paquete para su uso

Attaching package: 'dplyr'

The following objects are masked from 'package:stats':

    filter, lag

The following objects are masked from 'package:base':

    intersect, setdiff, setequal, union
```

- Para extraer (filtrar) un subconjunto de filas que cumplen con un criterio con base a condiciones lógicas, se usa:
  - filtrado <- **filter(***objeto* **,** *condiciones***)**
- Operadores lógicos

Logical Operators in the R Environment			
<	Less than	>	Greater than
<=	Less than or equal to	>=	Greater than or equal to
==	Equal to	!=	Not equal to
%in%	Group membership	&, |, !, xor, any, and all	Boolean operators
is.na	Is NA	!is.na	Is not NA

UNIVERSIDAD DE GUANAJUATO

- Listar los registros donde no hay ninguna renta iniciada por usuarios registrados durante la temporada de primavera (1) o verano (2)

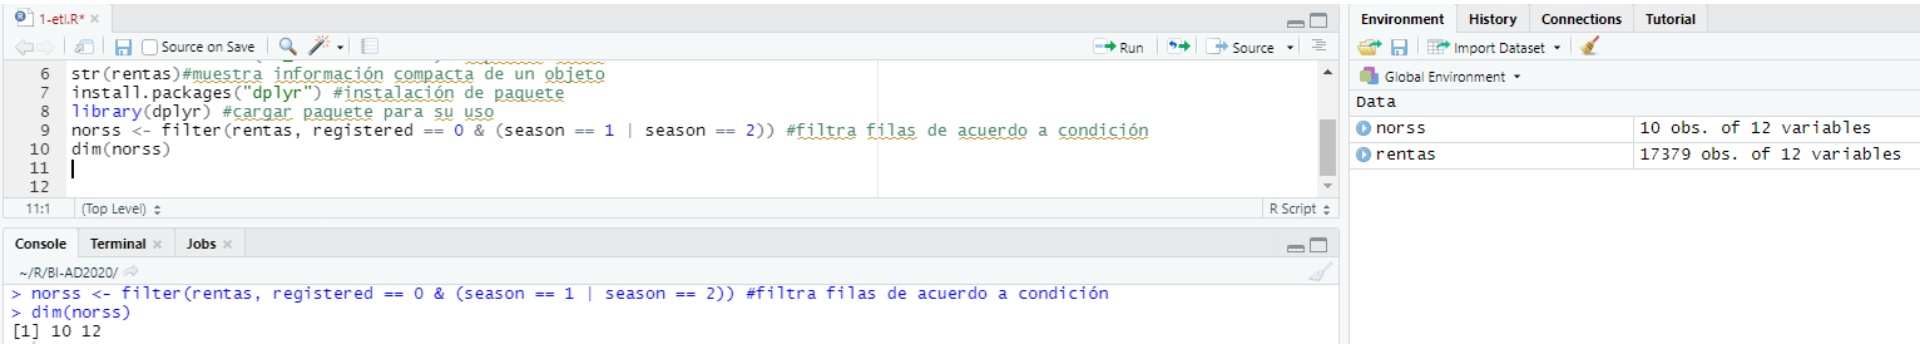

Nota: **dim(***objeto***)** regresa la dimensión de un objeto

Transformando datos: Seleccionando columnas

UNIVERSIDAD DE GUANAJUATO

- Para extraer (seleccionar) las columnas que se desean conservar, se usa
  - seleccionado <- **select(***objeto* **,** *atr_1, … atr_n***)**
- De los registros filtrados, solo mostrar la temporada y la cantidad de clientes casuales que iniciaron una renta

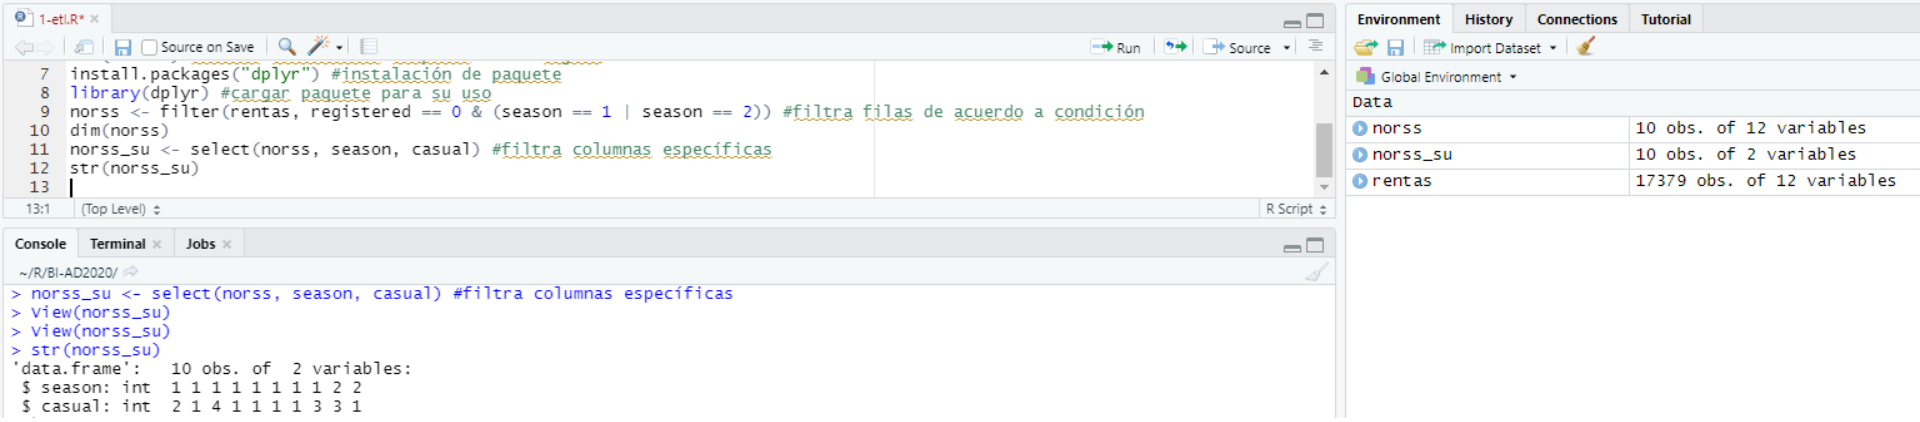

Transformando datos: Agregando columna calculada a los datos

UNIVERSIDAD DE GUANAJUATO

- Para generar una columna con valores derivados de los datos existentes, se usa:
  - derivado <- **mutate(***objeto* **,** *nueva_columna=calculo***)**
- De la consulta previa, calcule los costos de renta obtenidos de los usuarios casuales. El costo por el pase de un día es de $5.00

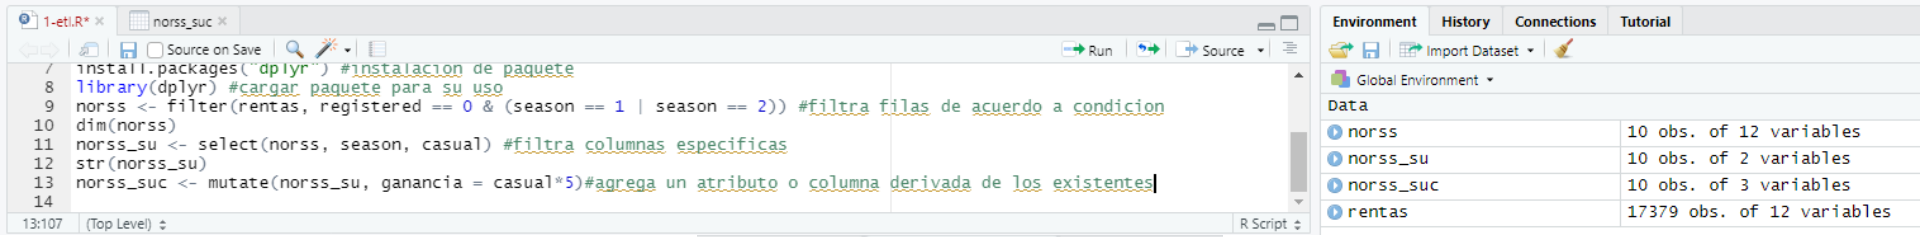

1-etl.R* | norss_suc

Filter

	season	casual	ganancia
1	1	2	10
2	1	1	5
3	1	4	20

- Para generar resúmenes de datos, son necesarias las siguientes dos funciones:
  - grupo <- **group_by(***objeto,atributo1, … , atributoN***)**
  - resumen <- **summarise(***obj_agrupado, función_agregación(atributoX), … , función_agregación(atributoZ)***)**

UNIVERSIDAD DE GUANAJUATO

- Reportar la cantidad de clientes casuales y el total de ganancias obtenidas de estos.

```
1-etl.R*
Source on Save | Run | Source
rentas <- read.csv( 1_etl-Bikes.csv ) #importar datos de csv
str(rentas)#muestra informacion compacta de un objeto
install.packages("dplyr") #instalacion de paquete
library(dplyr) #cargar paquete para su uso
norss <- filter(rentas, registered == 0 & (season == 1 | season == 2)) #filtra filas de acuerdo a condicion
dim(norss)
norss_su <- select(norss, season, casual) #filtra columnas especificas
str(norss_su)
norss_suc <- mutate(norss_su, ganancia = casual*5)#agrega un atributo o columna derivada de los existentes
gpo_norss <- group_by(norss_suc, season)#agrupa elementos por estación del año
sum_norss <- summarise(gpo_norss, sum(casual), sum(ganancia)) #obtiene la cantidad de clientes casuales y ganancias
```

Environment | History | Connections | Tutorial

Import Dataset | Global Environment

Data

gpo_norss	10 obs. of 3 variables
norss	10 obs. of 12 variables
norss_su	10 obs. of 2 variables
norss_suc	10 obs. of 3 variables
rentas	17379 obs. of 12 variables
sum_norss	2 obs. of 3 variables

1-etl.R* | sum_norss

Filter

	season	sum(casual)	sum(ganancia)
1	1	14	70
2	2	4	20

Cargando datos: Escribiendo datos a un CSV u otro tipo de archivo

UNIVERSIDAD DE GUANAJUATO

- Los datos transformados pueden ser guardados mediante las siguientes funciones:
  - **write.csv(***objeto, "{nombre_archivo}.csv"***, row.names=FALSE)**
  - **write.table(***objeto, "{nombre_archivo}.txt"***, row.names=FALSE, sep="\t")**

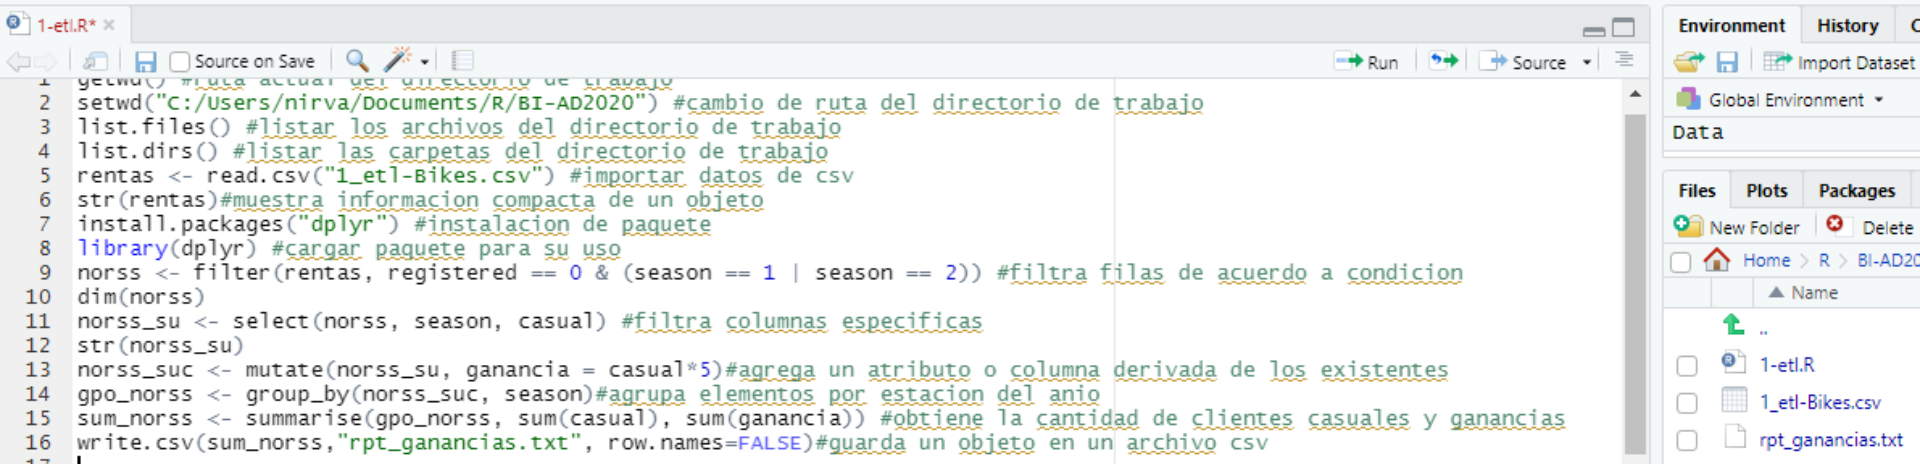

LIMPIEZA DE LOS DATOS

- Datos pobres o de baja calidad es la principal razón de problemas en análisis de inteligencia de negocios.
- La limpieza de los datos es el proceso de transformar datos brutos en datos utilizables.

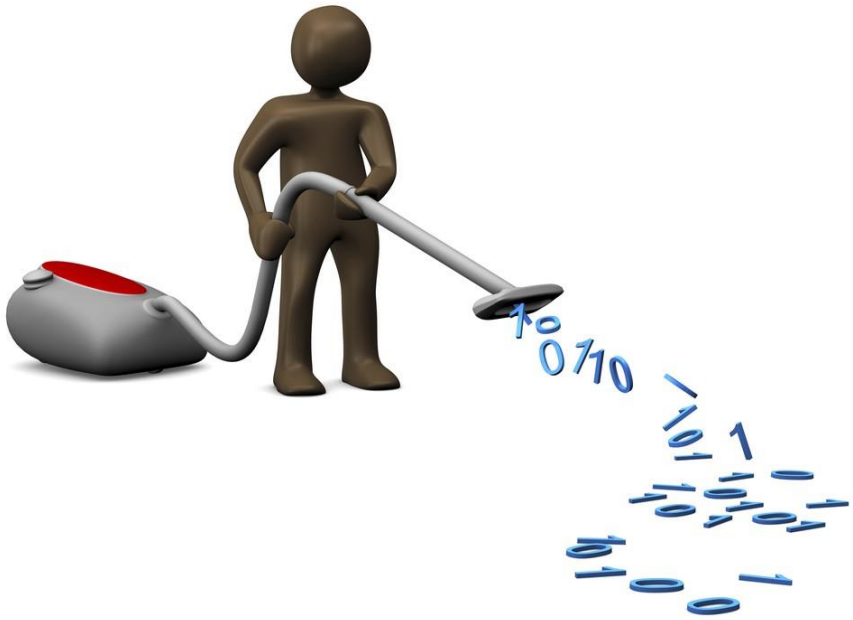

- Como analista de negocios, te han llegado nuevos datos. A diferencia del primer conjunto de datos, los nuevos están en bruto. Es necesario que realices una limpieza a estos datos y tenerlos listos para futuros análisis.
- Siga el enfoque Resumir-Reparar-Convertir-Adaptar (Summarize-Fix-Convert-Adapt -SFCA-) para realizar la limpieza de los datos.

UNIVERSIDAD DE GUANAJUATO

- Para resumir un conjunto de datos, se hace uso de la función **str(*objeto*)**

2-dc.R*

Source on Save

```
1  new_data <- read.csv("2_dc-Bikes.csv") #cargamos datos de un csv
2  str(new_data) #resumimos los datos para una inspeccion
3
```

2:55 (Top Level)

Console Terminal Jobs

~/R/BI-AD2020/

```
> new_data <- read.csv("2_dc-Bikes.csv")
> str(new_data)
'data.frame':   17379 obs. of  13 variables:
 $ datetime  : chr  "1/1/2011 0:00" "1/1/2011 1:00" "1/1/2011 2:00" "1/1/2011 3:00" ...
 $ season    : int  1 1 1 1 1 1 1 1 1 1 ...
 $ holiday   : int  0 0 0 0 0 0 0 0 0 0 ...
 $ workingday: int  0 0 0 0 0 0 0 0 0 0 ...
 $ weather   : int  1 1 1 1 1 2 1 1 1 1 ...
 $ temp      : num  9.84 9.02 9.02 9.84 9.84 ...
 $ atemp     : num  14.4 13.6 13.6 14.4 14.4 ...
 $ humidity  : chr  "81" "80" "80" "75" ...
 $ windspeed : num  0 0 0 0 0 ...
 $ casual    : int  3 8 5 3 0 0 2 1 1 8 ...
 $ registered: int  13 32 27 10 1 1 0 2 7 6 ...
 $ count     : int  16 40 32 13 1 1 2 3 8 14 ...
 $ sources   : chr  "ad campaign" "www.yahoo.com" "www.google.fi" "AD campaign" ...
```

¿Qué podemos observar?

- Otras funciones para ver características de los datos, son:
  - **dim(*objeto*)** : obtiene número de renglones y columnas
  - **head(*objeto*)** : permite observar los primeros 6 registros de los datos
  - **tail(*objeto*)** : permite observar los últimos 6 registros de los datos

Reparando valores defectuosos: Valores faltantes

UNIVERSIDAD DE GUANAJUATO

- Los valores faltantes (NA) o nulos (NULL) provocan diversas dificultades para los métodos de análisis.
- Para encontrar valores faltantes, existe la función:

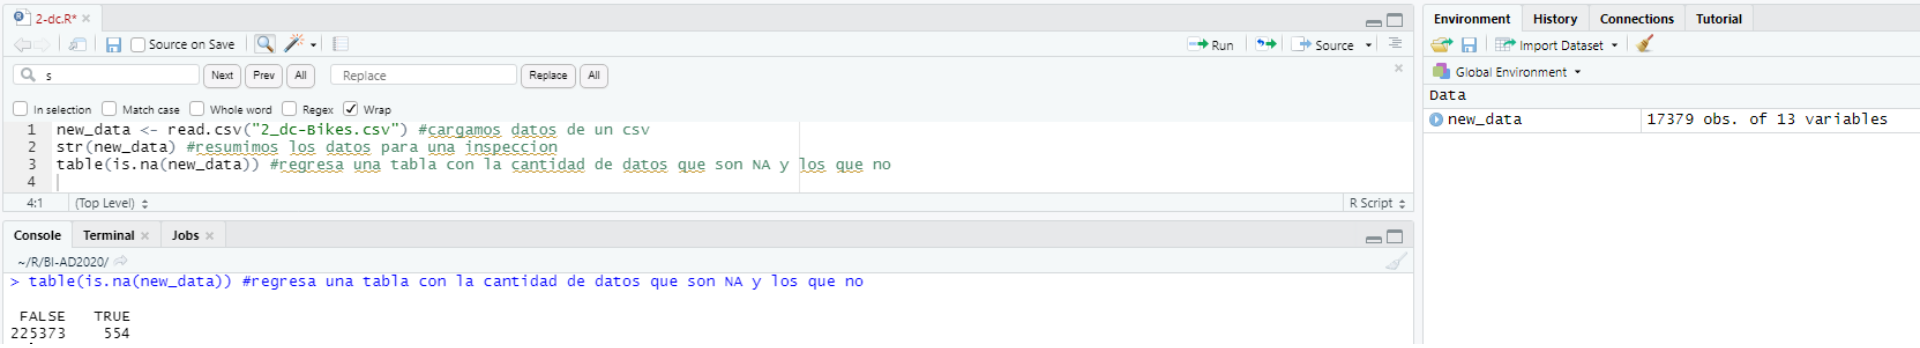

Reparando valores defectuosos: Valores faltantes

UNIVERSIDAD DE GUANAJUATO

- Los valores faltantes o nulos provocan diversas dificultades para los métodos de análisis.
- Para encontrar valores faltantes, existe la función:
  - **is.na(*objeto*)**

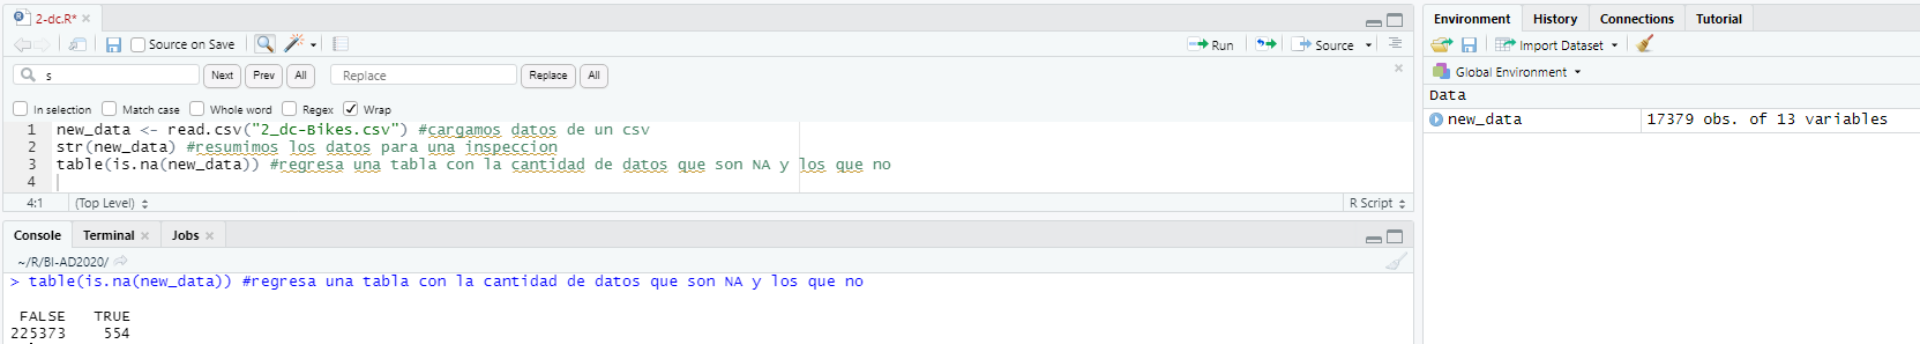

Nota: Valores Especiales en R

UNIVERSIDAD DE GUANAJUATO

- ± Infinity: resulta de almacenar un ´numero muy grande o el resultado de una división entre cero.
- NaN: aplica a valores numéricos (reales y complejos) e indica que no es algo no es un numero.
- NA (Not Available): Constante lógica que indica valor faltante
- Null: es un objeto devuelto cuando una expresión o función resulta en un valor indefinido.

```
> x <- c(1.5, Inf, -Inf, 3)
> is.infinite(x)
[1] FALSE  TRUE  TRUE FALSE
> x <- c(-Inf, -1, 0/0, 1, Inf)
> x
[1] -Inf   -1  NaN    1  Inf
> is.nan(x)
[1] FALSE FALSE  TRUE FALSE FALSE
> x <- c(-Inf, -1, 0/0, 1, Inf, NA)
> x
[1] -Inf   -1  NaN    1  Inf   NA
> is.na(x)
[1] FALSE FALSE  TRUE FALSE FALSE  TRUE
> x <- c(-Inf, -1, 0/0, 1, Inf, NULL, NULL, NA)
> x
[1] -Inf   -1  NaN    1  Inf   NA
> is.null(x)
[1] FALSE
> x <- c(NULL,NULL)
> is.null(x)
[1] TRUE
> x
NULL
```

- Para trabajar con los valores faltantes, se puede:
  - Eliminar las observaciones con problemas
  - Imputar los datos - reparar los datos faltantes basado en algún método, como:
    - Tomar muestras aleatorias
    - Usar la media de una variable o de un grupo
    - Generar valores basados en modelos predictivos

UNIVERSIDAD DE GUANAJUATO

- Las funciones del paquete *stringr*, nos permiten detectar cadenas
  - **install.packages(***"stringr"***)**
  - **library(***stringr***)**
- Para encontrar los elementos con la cadena *"NA"*, se usa:
  - **str_detect(***objeto, cadena***)**

```
5  install.packages("stringr") #instalacion de paquete para reparar valores NA
6  library(stringr)
7  str_detect(new_data, "NA") #Encontrar una cadena en un conjunto de valores
8
```

8:1 (Top Level) R S

Console Terminal Jobs

~/R/BI-AD2020/

```
> str_detect(new_data, "NA") #Encontrar una cadena en un conjunto de valores
 [1] FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE  TRUE
Warning message:
In stri_detect_regex(string, pattern, negate = negate, opts_regex = opts(pattern)) :
  argument is not an atomic vector; coercing
```

UNIVERSIDAD DE GUANAJUATO

- El valor *"NA"* se encuentra en la columna #13

```
8  table(is.na(new_data[13])) #Detectar valores NA en la columna 13
9
```

9:1 (Top Level)

Console | Terminal | Jobs

~/R/BI-AD2020/

```
> table(is.na(new_data[13])) #Detectar valores NA en la columna 13

FALSE  TRUE
16825   554
```

- ¿La solución? se verá al llegar a la parte de Adaptar en el proceso SFCA.

UNIVERSIDAD DE GUANAJUATO

- Un error detectado en la primera parte de SFCA, es el que la variable humedad en lugar de ser numérica, es almacenada como tipo carácter. El problema se puede encontrar buscando todas las instancias con valores diferentes a los numéricos en dicha variable. Para esto, se usara la siguiente función del paquete *stringr*:
  - coincidencias <- **str_subset(***objeto,* **reg_ex)**

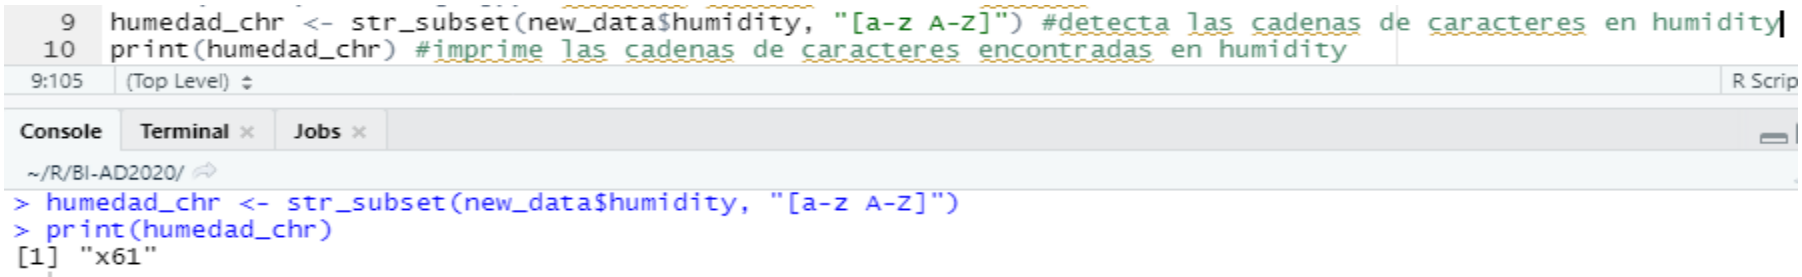

UNIVERSIDAD DE GUANAJUATO

- El error encontrado parece ser tipográfico y se decide no eliminar el registro, sino imputarlo:

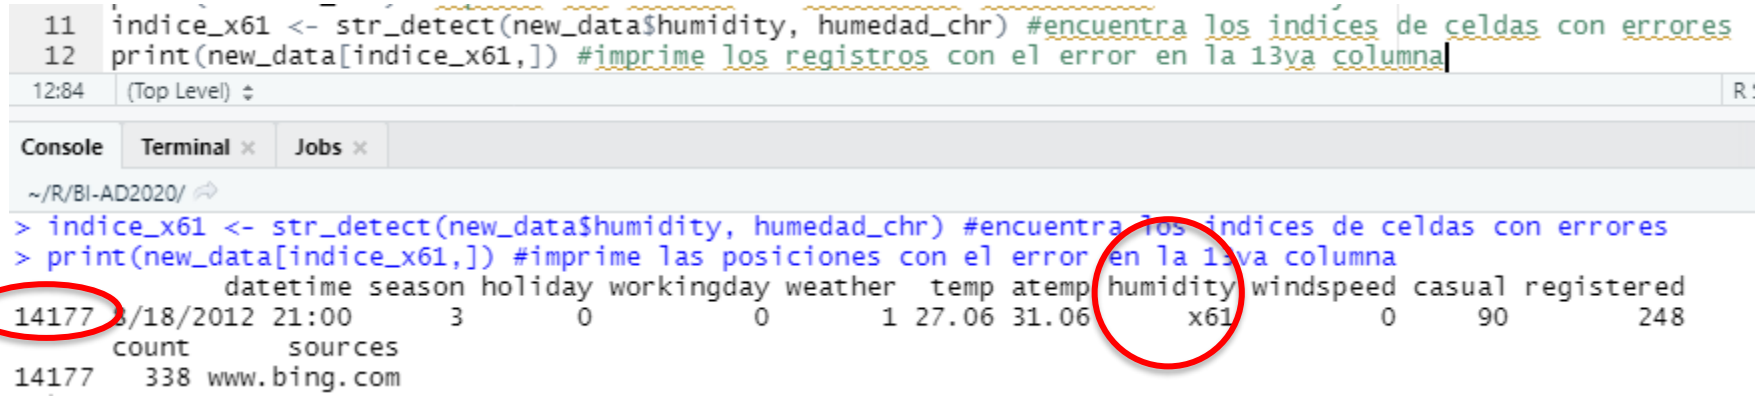

- Para reparar este error, se usará la siguiente función del paquete *stringr*:
  - objeto <- **str_replace_all(***objeto, índices, nvo_val***)**

Reparando valores defectuosos: Valores faltantes

UNIVERSIDAD DE GUANAJUATO

```
13 new_data$humidity <- str_replace_all(new_data$humidity, humedad_chr, "61") #reemplaza el valor x61 por 61
14 print(new_data[indice_x61,]) #imprime los registros corregidos
15
```

15:1 (Top Level) R Script

Console Terminal Jobs

~/R/BI-AD2020/

```
> new_data$humidity <- str_replace_all(new_data$humidity, humedad_chr, "61") #reemplaza el valor x61 por 61
> print(new_data[indice_x61,]) #imprime los registros corregidos
            datetime season holiday workingday weather  temp atemp humidity windspeed casual registered
14177 8/18/2012 21:00      3       0          0       1 27.06 31.06       61         0     90        248
      count      sources
14177   338 www.bing.com
```

- Diferentes tipos de datos encontrados en el archivo de la compañía Bicicleta Compartida:

Data type	Explanation	Example
Numeric	A number having a decimal value	`9.84`
Integer	A number without decimals	`3`
Character	A string variable	`"www.google.com"`
Factor	A categorical variable that has a character and integer representation	`"ad campaign", "blog": 1,2`
Date	A date or time in various formats	`2016-02-16 18:56:57 EST`

¿Por qué se necesita conversión entre tipos de datos?

Convirtiendo entradas a tipos de datos adecuados para análisis: Carácter a Numero (o entero)

UNIVERSIDAD DE GUANAJUATO

- Para realizar una conversión de carácter a numero, R cuenta con funciones de conversión de tipo:
  - **as.{type}**
- En los datos nuevos, se ha corregido el problema tipográfico en humidity, sin embargo, el tipo de dato aun es carácter. Solución:

```
15 str(new_data$humidity) #visualizar un resumen de los datos
16 new_data$humidity <- as.numeric(new_data$humidity) #cambia los datos en humidity de caracter a numero
17 str(new_data$humidity) #visualizar un resumen de los datos
```

17:59 (Top Level) R

Console Terminal Jobs

~/R/BI-AD2020/

```
> str(new_data$humidity) #visualizar un resumen de los datos
 chr [1:17379] "81" "80" "80" "75" "75" "75" "80" "86" "75" "76" "76" "81" "77" "72" "72" "77" "82" ...
> new_data$humidity <- as.numeric(new_data$humidity) #cambia los datos en humidity de caracter a numero
> str(new_data$humidity) #visualizar un resumen de los datos
 num [1:17379] 81 80 80 75 75 75 80 86 75 76 ...
```

- En R, los factores son la forma mas natural de representar puntos de datos que caen dentro de un número finito de distintas categorías; en lugar de pertenecer a un espacio continuo de valores.

- Para transformar variables numéricas que realmente son categóricas, se hace a través de factores, la forma es la siguiente:
  - obj_factor <- **factor(***objeto***, levels =** *v_niveles***, labeles =** *v_etiquetas***)**

Convirtiendo entradas a tipos de datos adecuados para análisis: Variables categóricas a Factor

UNIVERSIDAD DE GUANAJUATO

- Es conveniente convertir los valores de las columnas *holiday* y *workingday* de *0* y *1* a “no” y “yes”, respectivamente, para una mejor lectura de los datos:

```
18 str(new_data$holiday) #visualizar un resumen de los datos
19 str(new_data$workingday) #visualizar un resumen de los datos
20 #convertir valores de 0 o 1 en columnas holiday y working day a factores con etiquetas no o si
21 new_data$holiday <- factor(new_data$holiday, levels = c(0,1), labels = c("no", "yes"))
22 new_data$workingday <- factor(new_data$workingday, levels = c(0,1), labels = c("no", "yes"))
23 str(new_data$holiday) #visualizar un resumen de los datos
24 str(new_data$workingday) #visualizar un resumen de los datos
25 n
19:54 (Top Level)
```

```
Console  Terminal  Jobs
~/R/BI-AD2020/
> str(new_data$holiday) #visualizar un resumen de los datos
 int [1:17379] 0 0 0 0 0 0 0 0 0 0 ...
> str(new_data$workingday) #visualizar un resumen de los datos
 int [1:17379] 0 0 0 0 0 0 0 0 0 0 ...
> #convertir valores de 0 o 1 en columnas holiday y working day a factores con etiquetas no o si
> new_data$holiday <- factor(new_data$holiday, levels = c(0,1), labels = c("no", "yes"))
> new_data$workingday <- factor(new_data$workingday, levels = c(0,1), labels = c("no", "yes"))
> str(new_data$holiday) #visualizar un resumen de los datos
 Factor w/ 2 levels "no","yes": 1 1 1 1 1 1 1 1 1 1 ...
> str(new_data$workingday) #visualizar un resumen de los datos
 Factor w/ 2 levels "no","yes": 1 1 1 1 1 1 1 1 1 1 ...
```

- Para transformar variables numéricas que realmente son categóricas, se hace a través de factores ordenados, la forma es la siguiente:
  - obj_factor <- **factor(***objeto***, levels =** *v_niveles***, labeles =** *v_etiquetas***, ordered = TRUE)**

Convirtiendo entradas a tipos de datos adecuados para análisis: Variables de escala ordinal a Factor

UNIVERSIDAD DE GUANAJUATO

- Ahora, resulta conveniente convertir los valores de las columnas *season* y *weather* en factores ordenados, para tener la noción de secuencia en las estaciones o variación del clima:

```
25 str(new_data$season) #visualizar un resumen de los datos
26 str(new_data$weather) #visualizar un resumen de los datos
27 new_data$season <- factor(new_data$season, levels = c(1, 2, 3, 4),
28                           labels = c("spring", "summer","fall", "winter"),
29                           ordered = TRUE)
30 new_data$weather <- factor(new_data$weather, levels = c(1, 2, 3, 4),
31                           labels = c("clr_part_cloud","mist_cloudy","lt_rain_snow","hvy_rain_snow"),
32                           ordered = TRUE)
33 str(new_data$season) #visualizar un resumen de los datos
34 str(new_data$weather) #visualizar un resumen de los datos
35 n
```

34:28 (Top Level)

Console Terminal Jobs

~/R/BI-AD2020/

```
> str(new_data$season) #visualizar un resumen de los datos
 int [1:17379] 1 1 1 1 1 1 1 1 1 1 ...
> str(new_data$weather) #visualizar un resumen de los datos
 int [1:17379] 1 1 1 1 1 2 1 1 1 1 ...
> new_data$season <- factor(new_data$season, levels = c(1, 2, 3, 4),
+                           labels = c("spring", "summer","fall", "winter"),
+                           ordered = TRUE)
> new_data$weather <- factor(new_data$weather, levels = c(1, 2, 3, 4),
+                            labels = c("clr_part_cloud","mist_cloudy","lt_rain_snow","hvy_rain_snow"),
+                            ordered = TRUE)
> str(new_data$season) #visualizar un resumen de los datos
 Ord.factor w/ 4 levels "spring"<"summer"<..: 1 1 1 1 1 1 1 1 1 1 ...
> str(new_data$weather) #visualizar un resumen de los datos
 Ord.factor w/ 4 levels "clr_part_cloud"<..: 1 1 1 1 1 2 1 1 1 1 ...
```

- Las funciones del paquete *lubridate*, nos permiten manipular fechas
  - **install.packages(***"lubridate"***)**
  - **library(***lubridate***)**
- Las funciones del paquete *lubridate* son nombradas usando letras representado el orden de los datos de entrada, por ejemplo:
  - **dmy_hm(***objeto***)** : muestra la fecha en formato de día, mes, año, hora y minutos
  - **mdy_hm(***objeto***)** : muestra la fecha en formato de mes, día, año, hora y minutos

Convirtiendo entradas a tipos de datos adecuados para análisis: Carácter a Fecha

UNIVERSIDAD DE GUANAJUATO

- Convertir los valores de la columna *datetime* de carácter a fecha en formato mes-día-año:

```
36 library(lubridate)
37 str(new_data$datetime) #visualizar un resumen de los datos
38 new_data$datetime <- mdy_hm(new_data$datetime)
39 str(new_data$datetime) #visualizar un resumen de los datos
40
```

40:1 (Top Level) R Script

Console Terminal Jobs

~/R/BI-AD2020/

```
> str(new_data$datetime) #visualizar un resumen de los datos
 chr [1:17379] "1/1/2011 0:00" "1/1/2011 1:00" "1/1/2011 2:00" "1/1/2011 3:00" "1/1/2011 4:00" ...
> new_data$datetime <- mdy_hm(new_data$datetime)
> str(new_data$datetime) #visualizar un resumen de los datos
 POSIXct[1:17379], format: "2011-01-01 00:00:00" "2011-01-01 01:00:00" "2011-01-01 02:00:00" "2011-01-01 03:00:0
0" ...
```

Nuestro conjunto de datos hasta ahora…

UNIVERSIDAD DE GUANAJUATO

```
> str(new_data)
'data.frame':   17379 obs. of  13 variables:
 $ datetime  : POSIXct, format: "2011-01-01 00:00:00" "2011-01-01 01:00:00" "2011-01-01 02:00:00" ...
 $ season    : Ord.factor w/ 4 levels "spring"<"summer"<..: 1 1 1 1 1 1 1 1 1 1 ...
 $ holiday   : Factor w/ 2 levels "no","yes": 1 1 1 1 1 1 1 1 1 1 ...
 $ workingday: Factor w/ 2 levels "no","yes": 1 1 1 1 1 1 1 1 1 1 ...
 $ weather   : Ord.factor w/ 4 levels "clr_part_cloud"<..: 1 1 1 1 1 2 1 1 1 1 ...
 $ temp      : num  9.84 9.02 9.02 9.84 9.84 ...
 $ atemp     : num  14.4 13.6 13.6 14.4 14.4 ...
 $ humidity  : num  81 80 80 75 75 75 80 86 75 76 ...
 $ windspeed : num  0 0 0 0 0 ...
 $ casual    : int  3 8 5 3 0 0 2 1 1 8 ...
 $ registered: int  13 32 27 10 1 1 0 2 7 6 ...
 $ count     : int  16 40 32 13 1 1 2 3 8 14 ...
 $ sources   : chr  "ad campaign" "www.yahoo.com" "www.google.fi" "AD campaign" ...
> head(new_data)
             datetime season holiday workingday        weather temp  atemp humidity windspeed casual
1 2011-01-01 00:00:00 spring      no         no clr_part_cloud 9.84 14.395       81    0.0000      3
2 2011-01-01 01:00:00 spring      no         no clr_part_cloud 9.02 13.635       80    0.0000      8
3 2011-01-01 02:00:00 spring      no         no clr_part_cloud 9.02 13.635       80    0.0000      5
4 2011-01-01 03:00:00 spring      no         no clr_part_cloud 9.84 14.395       75    0.0000      3
5 2011-01-01 04:00:00 spring      no         no clr_part_cloud 9.84 14.395       75    0.0000      0
6 2011-01-01 05:00:00 spring      no         no    mist_cloudy 9.84 12.880       75    6.0032      0
  registered count       sources
1         13    16   ad campaign
2         32    40 www.yahoo.com
3         27    32 www.google.fi
4         10    13   AD campaign
5          1     1       Twitter
6          1     1  www.bing.com
```

UNIVERSIDAD DE GUANAJUATO

- Revisemos que valores hay en la columna *source*. Esto lo logramos mediante la función:
  - **unique(*objeto*)**

```
40 unique(new_data$sources) #permite obtener los valores únicos en un vector
41
41:1  (Top Level)
```

Console | Terminal | Jobs

```
~/R/BI-AD2020/
> unique(new_data$sources) #permite obtener los valores únicos en un vector
 [1] "ad campaign"      "www.yahoo.com"    "www.google.fi"    "AD campaign"      "Twitter"
 [6] "www.bing.com"     "www.google.co.uk" "facebook page"    "Ad Campaign"      "Twitter    "
[11] NA                 "www.google.com"   "direct"           "blog"
```

¿Convendrá hacer de esta columna un factor?

¿Cuántos valores tendría nuestro factor?

- Empecemos por estandarizar los valores en *source.*
- Para evitar duplicados por variaciones de mayúsculas y minúsculas, dejemos todo en minúsculas con la siguiente función:
  - objeto <- **tolower(***objeto_str***)**
- Para evitar redundancia de valores por espacios "de más", usaremos la función:
  - objeto <- **str_trim(***objt_str***)**
- Por último, cambiaremos los valores NA por la palabra "unknown" con una función ya vista (**is.na**)**.**

Adaptando cadenas de caracteres a un estándar de valor

UNIVERSIDAD DE GUANAJUATO

```
41 new_data$sources <- tolower(new_data$sources) #cambia todas las letras a minusculas
42 unique(new_data$sources)
43 new_data$sources <- str_trim(new_data$sources) #quita espacios en blanco al inicio y fin de la cadena
44 unique(new_data$sources)
45 indice_na <- is.na(new_data$sources) #detecta las incidencias NA
46 new_data$sources[indice_na] <- "unknown"
47 unique(new_data$sources)
48
```

40:11 (Top Level)

Console Terminal Jobs

~/R/BI-AD2020/

```
> new_data$sources <- tolower(new_data$sources) #cambia todas las letras a minusculas
> unique(new_data$sources)
 [1] "ad campaign"      "www.yahoo.com"    "www.google.fi"    "twitter"          "www.bing.com"
 [6] "www.google.co.uk" "facebook page"    "twitter    "      NA                 "www.google.com"
[11] "direct"           "blog"
> new_data$sources <- str_trim(new_data$sources) #quita espacios en blanco al inicio y fin de la cadena
> unique(new_data$sources)
 [1] "ad campaign"      "www.yahoo.com"    "www.google.fi"    "twitter"          "www.bing.com"
 [6] "www.google.co.uk" "facebook page"    NA                 "www.google.com"   "direct"
[11] "blog"
> indice_na <- is.na(new_data$sources) #detecta las incidencias NA
> new_data$sources[indice_na] <- "unknown"
> unique(new_data$sources)
 [1] "ad campaign"      "www.yahoo.com"    "www.google.fi"    "twitter"          "www.bing.com"
 [6] "www.google.co.uk" "facebook page"    "unknown"          "www.google.com"   "direct"
[11] "blog"
```

Contar con 11 diferentes categorías ¿es suficiente o adecuado?

- Según la *Ley de Miller* (1956): La mente humana trabaja mejor con "cosas" o categorías que aparecen en cantidades de 7 (+/- 2). Con base a esto, intentemos quedarnos con una cantidad de categorías entre 5-7.
- Como tip: Las personas de publicidad, no consideran importante conocer el motor de búsqueda sino que una persona encontró la compañía en la Web.

- Las funciones del paquete *DataCombine*, nos permiten combinar datos para definir nuevas categorías
  - **install.packages(***"DataCombine"***)**
  - **library(***DataCombine***)**

- En R, los Data Frames son la forma de presentar un conjunto de datos formado por una colección de observaciones registradas para una o más variables.
- Al igual que las listas, los Data Frames no tienen restricción en los tipos de datos de las variables.
- Un aspecto importante, es que los miembros del Data Frame deben ser vectores del mismo tamaño.

- Creamos un patrón para los sitios web mediante una expresión regular: *"(www.[a-z]*.[a-z]*)"*
- Obtenemos los valores que coinciden con este criterio de búsqueda, esto a través de las funciones **str_subset** y **unique**.
- Generamos un vector del tamaño de las incidencias de sitio web, esto mediante la función:
  - objeto <- **rep(**valor**,** cantidad**)**

- Definimos un data frame que contenga las incidencias de sitios web y la cadena de remplazo:
  - objeto <- **data.frame(***col1=vec1***, … ,** *coln=vecn***)**
- Reemplazamos las incidencias de sitios web por la palabra "*web*" con base al data frame creado
  - objeto <- **FindReplace(data=***objeto***, var=***columna***, from=***val_original_df***, to=***val_cambio_df***, exact=**FALSE**)**

- Definimos la columna *source* como factor
  - objeto <- **as.factor(***valores***)**
- Escribimos un csv con los datos limpios

Adaptando cadenas de caracteres a un estándar de valor

UNIVERSIDAD DE GUANAJUATO

```
install.packages("DataCombine")  #instalacion de paquete para combinar datos
library(DataCombine)
wb <- "(www.[a-z]*.[a-z]*)" #expresion regular para buscar combinaciones tipo sitio web
sts <- unique(str_subset(new_data$sources, wb)) #se obtienen las cadenas que son tipo sitio web
rplc <- rep("web", length(sts)) #crea un vector con la palabra web de tamaño tantos sitios haya
rplcmts <- data.frame(ori = sts, rep = rplc) #crea un vector con la asociacion de sitio y reemplazo
#FindReplace permite cambiar datos en from por los de to en un objeto cadena
new_data <- FindReplace(data=new_data, Var="sources", rplcmts, from="ori", to="rep", exact = FALSE)
unique(new_data$sources)
new_data$sources <- as.factor(new_data$sources)
str(new_data)
write.csv(new_data,"cleaned_new_data.csv", row.names=FALSE)
```

```
onsole  Terminal  Jobs
-/R/BI-AD2020/
 ?FindReplace
 wb <- "(www.[a-z]*.[a-z]*)" #expresion regular para buscar combinaciones tipo sitio web
 sts <- unique(str_subset(new_data$sources, wb)) #se obtienen las cadenas que son tipo sitio web
 rplc <- rep("web", length(sts)) #crea un vector con la palabra web de tamaño tantos sitios haya
 rplcmts <- data.frame(ori = sts, rep = rplc) #crea un vector con la asociacion de sitio y reemplazo
 #FindReplace permite cambiar datos en from por los de to en un objeto cadena
 new_data <- FindReplace(data=new_data, Var="sources", rplcmts, from="ori", to="rep", exact = FALSE)
 unique(new_data$sources)
1] "ad campaign"   "web"           "twitter"       "facebook page" "unknown"       "direct"
7] "blog"
 new_data$sources <- as.factor(new_data$sources)
 str(new_data)
data.frame':   17379 obs. of  13 variables:
$ datetime  : POSIXct, format: "2011-01-01 00:00:00" "2011-01-01 01:00:00" "2011-01-01 02:00:00" ...
$ season    : Ord.factor w/ 4 levels "spring"<"summer"<..: 1 1 1 1 1 1 1 1 1 1 ...
$ holiday   : Factor w/ 2 levels "no","yes": 1 1 1 1 1 1 1 1 1 1 ...
$ workingday: Factor w/ 2 levels "no","yes": 1 1 1 1 1 1 1 1 1 1 ...
$ weather   : Ord.factor w/ 4 levels "clr_part_cloud"<..: 1 1 1 1 1 2 1 1 1 1 ...
$ temp      : num  9.84 9.02 9.02 9.84 9.84 ...
$ atemp     : num  14.4 13.6 13.6 14.4 14.4 ...
$ humidity  : num  81 80 80 75 75 75 80 86 75 76 ...
$ windspeed : num  0 0 0 0 0 0 ...
$ casual    : int  3 8 5 3 0 0 2 1 1 8 ...
$ registered: int  13 32 27 10 1 1 0 2 7 6 ...
$ count     : int  16 40 32 13 1 1 2 3 8 14 ...
$ sources   : Factor w/ 7 levels "ad campaign",..: 1 7 7 1 5 7 1 7 7 7 ...
```

UNIVERSIDAD DE GUANAJUATO